

Denoising Diffusion Restoration Models, DDRM

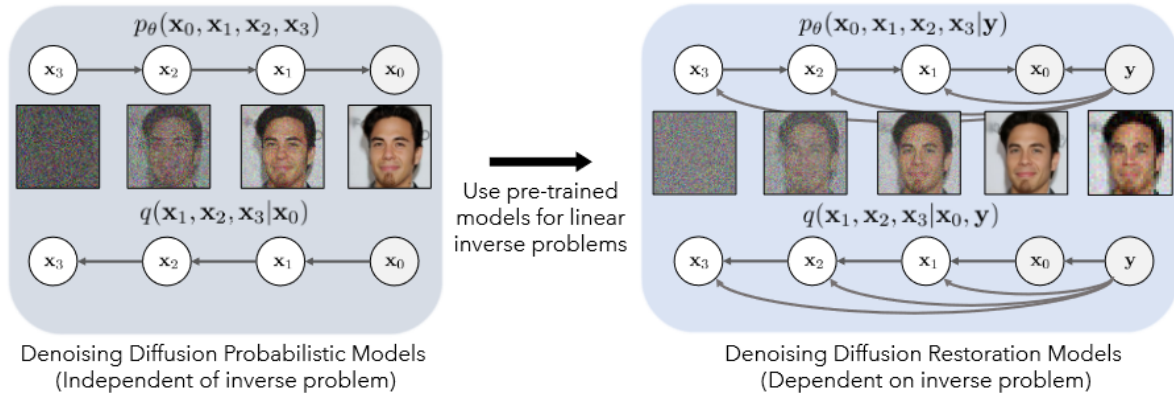
Introduction

对于一般的Diffusion模型 (基于Denoising Diffusion Probabilistic Model, DDPM) 来说, 它们使用后验分布进行低效的有监督迭代. DDRM 提出了一种高效的无监督后验迭代方案. DDRM不仅能做降噪, 在超分辨率等方面都能取得很好的效果(humm,, of course...), 是第一个通用逆采样求解器.

创新点:

- 高效, DDPM需要1k以上Step, 它只需要20左右Step;
- 是个通用方法, 能求解很多问题;
- 在降噪问题上尤为擅长, 因为它可以很好地保留输入信息的基本信息.

Model



相比于DDPM, 公式表达上仅添加蓝色部分, 意思是每一 step 都与输入信号 y 有关, 即每一次扩散和采样的结果都忠实于测量值 y .

$$p_\theta(x^{(0:T)} | \mathbf{y}) = p_\theta^{(T)}(x^{(T)} | \mathbf{y}) \prod_{i=1}^{T-1} p_\theta^{(t)}(x^{(t-1)} | x^{(t)}, \mathbf{y})$$

$$q(x^{(1:T)} | x^{(0)}, \mathbf{y}) = q^{(T)}(x^{(T)} | x^{(0)}, \mathbf{y}) \prod_{t=1}^{T-1} q^{(t)}(x^{(t)} | x^{(t-1)}, x^{(0)}, \mathbf{y})$$

公式存在和之前笔记有点不同的解释, 但我看过后认为意思不变, 因此对公式进行了轻微调整.

对于一个线性逆问题, 可以表示为:

$$y = \mathbf{H}x + z, \text{ where } \mathbf{H} \in \mathbb{R}^{m \times n}, x \in \mathbb{R}^n, y \in \mathbb{R}^m, z \sim \mathcal{N}(0, \sigma_y^2 \mathbf{I})$$

其中, 我们希望从测量值 y 恢复信号 x . 实现上, 可以使用SVD计算 \mathbf{H} . 通过SVD, 从数据 x 中识别 y 中缺失的信息.

$$\mathbf{H} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$$

$\mathbf{\Sigma}$ 中包含 \mathbf{H} 的奇异值, 并将奇异值降序排列. 其他定义, 一般来说, 奇异值对于 $m \leq n$, 但该方法同样有效于 $m \geq n$. 假设: 表示奇异值为 $s_1 \geq s_2 \geq \dots \geq s_m$, 定义 $s_i = 0, i \in [m+1, n]$.

定义如下简化符号:

- $\bar{x}_i^{(t)}$ 是 $\bar{x}^{(t)} = V^T x^{(t)}$ 的第*i*个元素, 由于 V 是正定的, 因此 $\bar{x}^{(t)}$ 和 $x^{(t)}$ 是可以相互恢复的;
- \bar{y}_i 是 $\bar{y} = \Sigma^\dagger U^T y$ 的第*i*个元素 (其中 \dagger 表示这是Moore-Penrose伪逆, 反正就是一种伪逆);

对于 \bar{x}_t 中每个元素, 可得到如下变分表达式:

$$q^{(T)}(\bar{x}_i^{(T)} | x_i^{(0)}, y) = \begin{cases} \mathcal{N}(\bar{y}_i, \sigma_T^2 - \frac{\sigma_y^2}{s_i^2}) & \text{if } s_i > 0 \\ \mathcal{N}(\bar{x}_i^{(0)}, \sigma_T^2) & \text{if } s_i = 0 \end{cases}$$

$$q^{(t)}(\bar{x}_i^{(t)} | x_i^{(t+1)}, x^{(0)}, y) = \begin{cases} \mathcal{N}(\bar{x}_i^{(0)} + \sqrt{1 - \eta^2} \sigma_t \frac{\bar{x}_i^{(t+1)} - \bar{x}_i^{(0)}}{\sigma_{t+1}}, \eta^2 \sigma_t^2) & \text{if } s_i = 0 \\ \mathcal{N}(\bar{x}_i^{(0)} + \sqrt{1 - \eta^2} \sigma_t \frac{\bar{y}_i - \bar{x}_i^{(0)}}{\sigma_y / s_i}, \eta^2 \sigma_t^2) & \text{if } \sigma_t < \frac{\sigma_y}{s_i} \\ \mathcal{N}((1 - \eta_b) \bar{x}_i^{(0)} + \eta_b \bar{y}_i, \sigma_t^2 - \frac{\sigma_y^2}{s_i^2} \eta_b^2) & \text{if } \sigma_t \geq \frac{\sigma_y}{s_i} \end{cases}$$

其中, $\eta \in (0, 1]$ 是一个超参数, 用于描述相变方差, 且 η 和 η_b 依赖于 σ_t, s_i, σ_y .

上公式的分布满足 $q(x^t | x^0) = \mathcal{N}(x^0, \sigma_t^2 \mathbf{I})$.

和DDPM类似, 本文目标得到对于 x^0 在每一步 t 的预测值. 为了简化变量, 定义符号 $x^{(\theta, t)}$ 表示由模型 $f_\theta(x^{(t+1)}, t+1) : \mathbb{R}^n \times \mathbb{R} \rightarrow \mathbb{R}^n$ 预测的值. 定义 $\bar{x}_i^{(\theta, t)}$ 为 $\bar{x}^{(\theta, t)} = V^T x^{(\theta, t)}$ 的第*i*个值.

由此得到DDRM的可训练参数 θ 的模型:

$$p_\theta^{(T)}(\bar{x}_i^{(T)} | y) = \begin{cases} \mathcal{N}(\bar{y}_i, \sigma_T^2 - \frac{\sigma_y^2}{s_i^2}) & \text{if } s_i > 0 \\ \mathcal{N}(\mathbf{0}, \sigma_T^2) & \text{if } s_i = 0 \end{cases}$$

$$p_\theta^{(t)}(\bar{x}_i^{(t)} | x_i^{(t+1)}, y) = \begin{cases} \mathcal{N}(\bar{x}_i^{(\theta, t)} + \sqrt{1 - \eta^2} \sigma_t \frac{\bar{x}_i^{(t+1)} - \bar{x}_i^{(\theta, t)}}{\sigma_{t+1}}, \eta^2 \sigma_t^2) & \text{if } s_i = 0 \\ \mathcal{N}(\bar{x}_i^{(\theta, t)} + \sqrt{1 - \eta^2} \sigma_t \frac{\bar{y}_i - \bar{x}_i^{(\theta, t)}}{\sigma_y / s_i}, \eta^2 \sigma_t^2) & \text{if } \sigma_t < \frac{\sigma_y}{s_i} \\ \mathcal{N}((1 - \eta_b) \bar{x}_i^{(\theta, t)} + \eta_b \bar{y}_i, \sigma_t^2 - \frac{\sigma_y^2}{s_i^2} \eta_b^2) & \text{if } \sigma_t \geq \frac{\sigma_y}{s_i} \end{cases}$$