

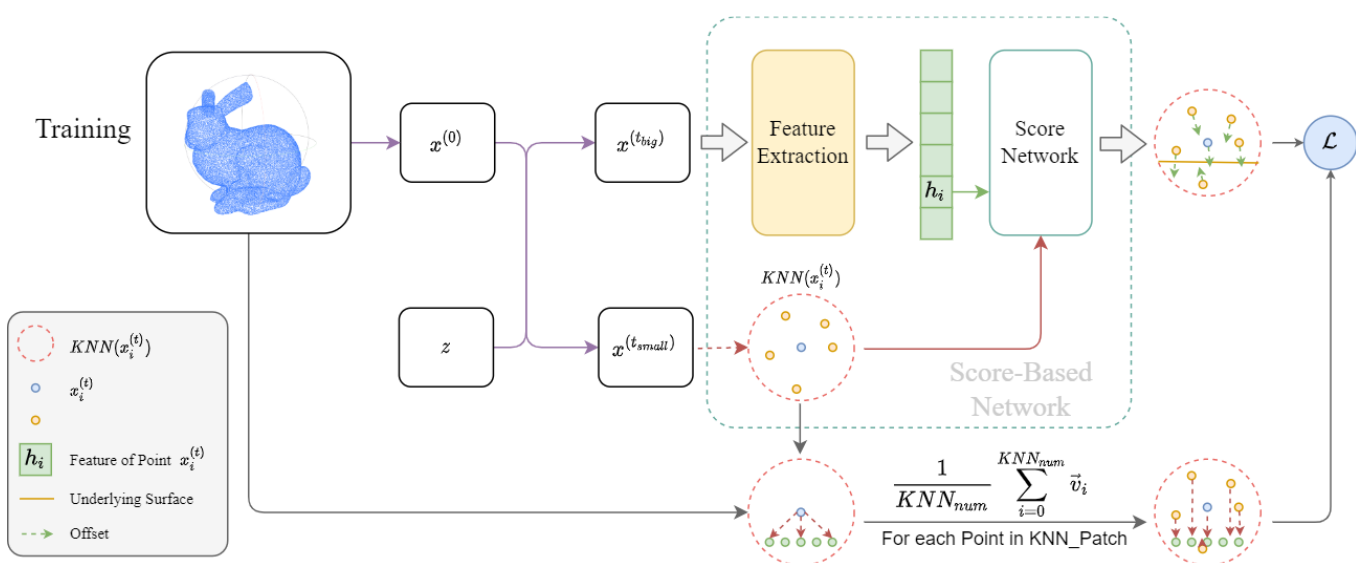
## 2\_26 周报

本周工作主要为下面几个：

1. 验证关于  $t_{small}, t_{big}$  的猜想，并得到了一个有理论依据的结论；
2. 统计了已有的点云降噪工作中使用的Dataset、Evaluation metric 和 Comparison；
3. 添加了两类可视化工具：包含更多的 Evaluation metric 和 CD-based 3d可视化。

关于训练中的扩散过程，我有一个基于随机微分方程 (Stochastic Differential Equation, SDE) 的推导思路，这是下周的一个尝试内容。

### 1. 更合理的 $t_{small}, t_{big}$ 生成策略



$t_{small}, t_{big}$  的生成策略决定了用于自监督的两个样本  $x^{(big)}, x^{(small)}$  的噪声程度的分布，实验证明：不同的生成策略会影响Sampling过程的好坏和对样本噪声的敏感度。

对于第  $t$  步的样本  $x^{(t)}$ ，它的噪声程度可通过如下公式计算：

$$L_t = \frac{\sqrt{1 - \bar{\alpha}_t}}{\sqrt{\bar{\alpha}_t}}$$

通过观察  $L_t$  的直方图，就可以快速判断采样样本的噪声程度的分布。

对于模型训练来说，只要迭代次数够多，那么模型可以对不同程度噪声的样本均有个较好的降噪效果。但不好的  $t_{small}, t_{big}$  生成策略会让训练的难度有非常夸张的增长。

下表为如下策略的训练结果（为了提高效率，我适当缩小了训练集，并确保理论上大方向上不影响训练结果）（控制变量： $t_{small}, t_{big}$  生成策略）：

策略 (测试噪声: 0.01)	CD (归一化)	Point-to-Surface	HD (标准化)

策略 (测试噪声: 0.01)	CD (归一化)	Point-to-Surface	HD (标准化)
2-11原始策略	0.000163490589	0.000110232998	0.015290613286
第一次尝试	太糟糕, 当时忘了记录	太糟糕, 当时忘了记录	太糟糕, 当时忘了记录
对第一次尝试的修改	<b>0.000141879517</b>	<b>0.000091748605</b>	<b>0.014466880076</b>

策略 (测试噪声: 0.02)	CD (归一化)	Point-to-Surface	HD (标准化)
2-11原始策略	0.000165044530	<b>0.000108053484</b>	<b>0.021538155992</b>
第一次尝试	太糟糕, 当时忘了记录	太糟糕, 当时忘了记录	太糟糕, 当时忘了记录
对第一次尝试的修改	<b>0.000163982048</b>	<b>0.000108601261</b>	0.022375815734

策略 (测试噪声: 0.03)	CD (归一化)	Point-to-Surface	HD (标准化)
2-11原始策略	<b>0.000196737230</b>	<b>0.000135074190</b>	<b>0.030974166933</b>
第一次尝试	太糟糕, 当时忘了记录	太糟糕, 当时忘了记录	太糟糕, 当时忘了记录
对第一次尝试的修改	0.000212527837	0.000150893815	0.032692635525


总结:

- 这次修改让模型可以更好地恢复低噪声点云, 且从训练梯度上可见还有稳定下降的空间;
- 原始策略在高噪声点云的恢复效果更好, 但训练时输出梯度和loss比较混乱, 且从32000开始就没有明显下降;
- 之前提出的增加displacement部分的loss没法看出效果

## 1.1. 基于 2\_11 的原始策略

原始的生成策略可用如下算法描述:

$$\begin{aligned}
 t_{small} &\leftarrow \text{Random}[0, \text{Step}] \\
 t_{big} &\leftarrow \text{Random}[t_{small}, \text{Step}]
 \end{aligned}$$



从直方图可知：

- $t_{big}$  对应的噪声样本大多集中在大噪声，低噪声样本较少；
- $t_{small}$  对应的噪声样本分布均匀；
- $t_{small} / t_{big}$  表明，模拟的Sampling过程集中在对大噪声的提取中；


综上可预测该策略训练的结果：

- 对大噪声的提取能力强，可以在噪声较大的样本中更准确地估计噪声；
- 缺乏细化能力，即对高频信息恢复能力较弱，对小噪声样本的恢复能力缺乏学习；

## 1.2. 第一次尝试：

$t_{big}$  对应的样本是输入噪声点云，因此均匀的  $t_{big}$  应该能让网络能更好处理不同噪声程度的输入噪声，因此算法修改如下：

$$\begin{aligned} t_{big} &\leftarrow \text{Random}[0, \text{Step}] \\ \text{ratio} &\leftarrow \text{Random}[0, 1] \\ t_{small} &\leftarrow t_{big} * \text{ratio} \end{aligned}$$



从直方图可知：

- $t_{big}$  对应的噪声样本均匀覆盖各种程度的噪声样本；
- $t_{small} / t_{big}$  非常均匀，意味着对于输入噪声样本  $x_{noise}$ ，采样均匀覆盖了采样的整个过程；

综上，该策略理论上的结果应该是：

- 对不同程度的噪声均能具有较好的提取效果；
- 对小噪声样本的降噪效果比原始方法更优；

但是，训练过了前期后完全无法收敛，最后结果也非常糟糕。

### 1.3. 对第一次尝试的分析与修改


分析：

首先，我回顾了我是用的Score-Based Net和Feature Net涉及的论文和代码，确定它们存在分布上的解释性。因此我认为可以通过分布解释第一次尝试失败的原因。

对于带噪声的点云，其中的一个点云切片可以通过一个至少4维的高维分布描述点的空间分布（如图中红色表示这些点对应的分布），即  $p_{noise} = p_{clear} * n, n \in \mathcal{N}(0, \sigma^2 I), \sigma > 0$ ，其中  $p_{noise}$  与  $p_{clear}$  的分布形式是不一样的，即  $p_{noise} = p_{clear} * n, n \in \mathcal{N}(0, \sigma^2 I), \sigma > \varepsilon, \exists \varepsilon > 0$ ，例如你用高斯分布拟合  $x = 0, \forall x \in X, |X| \rightarrow \infty$  的点集，结果是得到方差为  $\sigma \rightarrow +\infty$ ，这并不合理。

由于计算机存在浮点位限制，因此这个情况就变为了当

$p_{noise} \neq p_{clear} * n, n \in \mathcal{N}(0, \sigma^2 I), 0 < \sigma < \varepsilon, \exists \varepsilon > 0$ ，更一般的解释是：噪声程度小于一定程度，就无法通过一个连续分布进行拟合。



因此第一次尝试失败的原因可以归纳与以下两个原因：

- $t_{big}$  随机的噪声程度太小，让 Feature Net 在理解上出现混淆；
- $t_{small}$  随机的噪声程度太小，让 Score-Based 在理解上出现混淆；


修改

因此修改上，进行如下考虑：

- 输入噪声点云的噪声集中在  $[0.01, 0.03]$ ，因此要让  $t_{big}$  对应的噪声样本集中在  $[0.01, 0.03]$ ；
- $t_{small}$  对应的噪声程度不能太小；

修改算法如下：

$$\begin{aligned} T : x &\rightarrow y, \quad x \in [0.01, 0.03] \quad y \in (0, Step][0.01, 0.03] \\ t_{big} &\leftarrow T(Random[0.01, 0.03]) \\ ratio &\leftarrow Random(0, 1] \\ t_{small} &\leftarrow t_{big} * ratio \end{aligned}$$



从直方图可知：

- $t_{big}$  对应的噪声样本均匀覆盖噪声区间  $[0.01, 0.03]$  ；
- $t_{small}$  对应的噪声样本避免了较小的噪声输入；
- $t_{small} / t_{big}$  非常均匀；

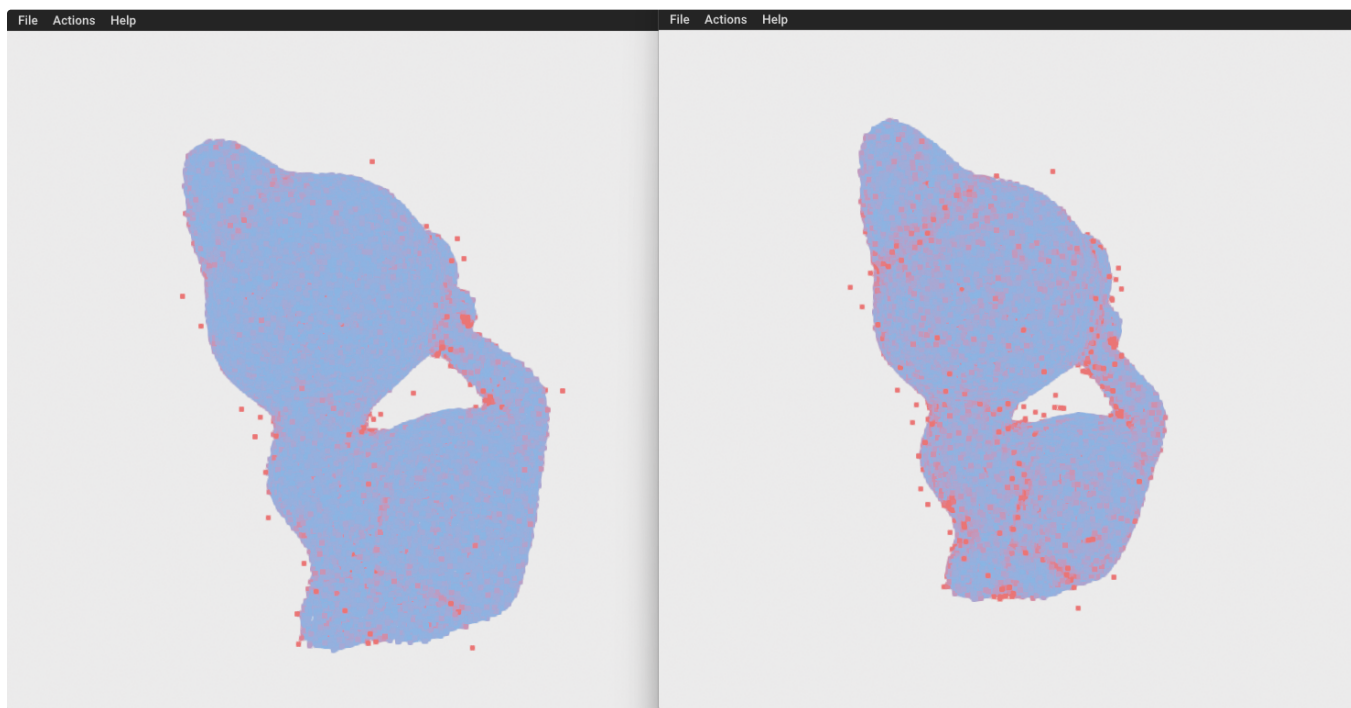
从指标中可知道：

- 上述对第一次尝试失败的分析是可行的；
- 对小噪声的降噪效果明显低于原始策略；
- 对大噪声的降噪效果变弱了，但可以通过提高迭代次数进行改善。

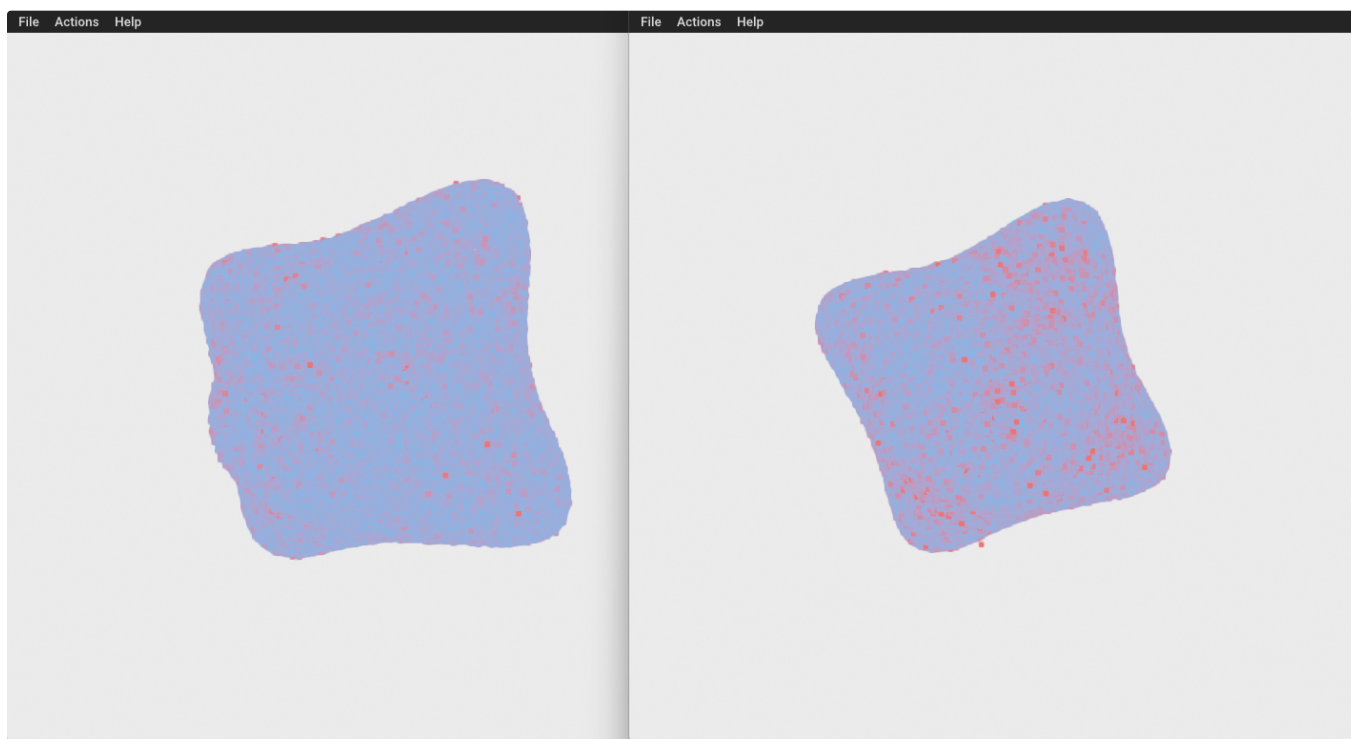
## 2. 基于可视化分析

由于训练集缩小，所以收敛得没有之前好，即存在一些离群点。之前实验发现，提高迭代次数可以有效减少离群点数量

左边：修改优化后的策略；右边：原始策略，样本：0.01噪声程度-kitten



左边：修改优化后的策略；右边：原始策略，样本：0.01噪声程度-star




### 从结果可见：

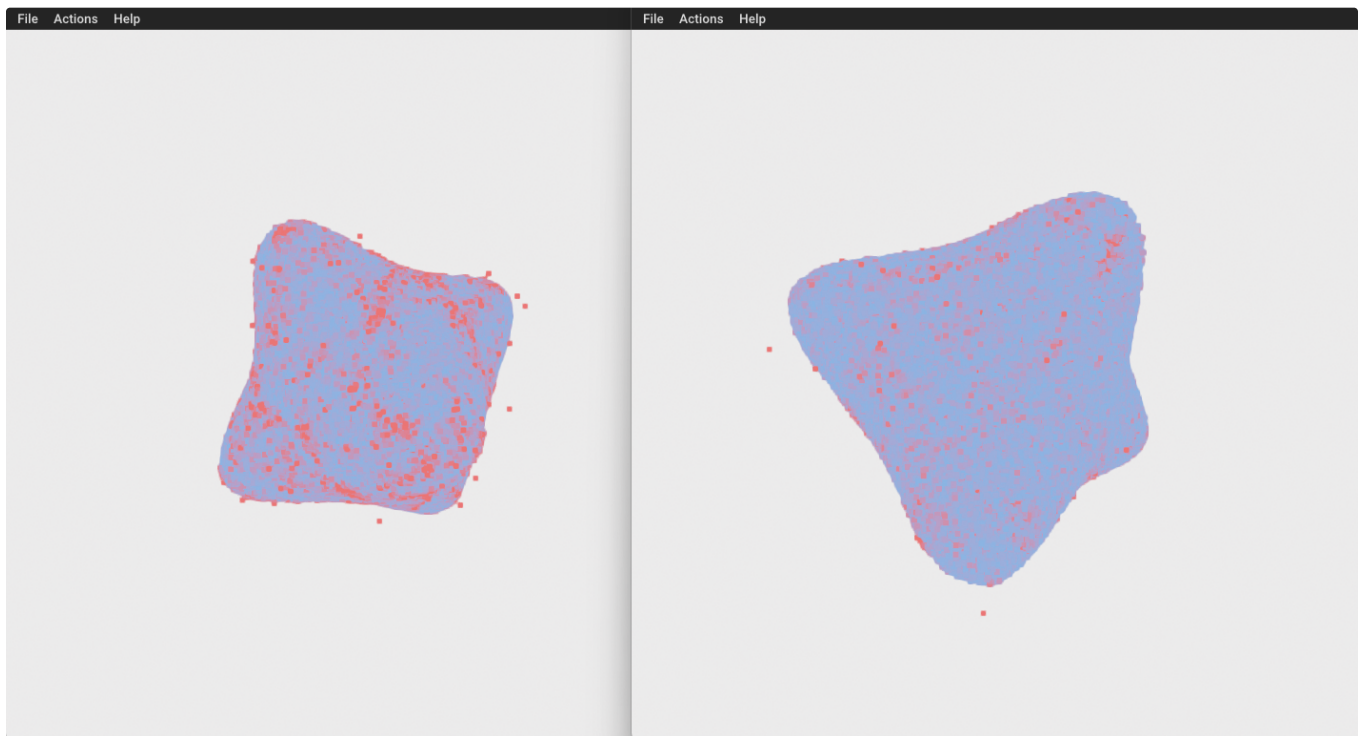
- 优化策略让模型更侧重于低频部分，对低噪声的高频部分恢复的也比原始策略好。

左边：修改优化后的策略；右边：原始策略，样本：0.03噪声程度-kitten





左边：修改优化后的策略；右边：原始策略，样本：0.03噪声程度-star



从结果可见：

- 优化策略在和原始策略相同迭代次数下，并没有那么擅长大噪声。